Django + RAG + Docker 프로덕션 아키텍처 및 구성 요소 분석

1. 전체 시스템 아키텍처 개요

본 문서는 Windows PC 환경에서 개발된 Django 기반의 멤버 게시판 및 RAG(Retrieval-Augmented Generation) 챗봇 시스템을 AWS EC2 Ubuntu 프로덕션 환경에 배포하고 운영하기 위한 전체 아키텍처와 각 구성 요소의 역할 및 데이터 흐름을 설명합니다.

[전체 요청 및 데이터 흐름 아키텍처]

1. 클라이언트(Windows PC 등)가 웹 브라우저를 통해 HTTPS/HTTP 요청을 보냅니다.
2. 요청은 SSH(22번 포트) 원격 관리 경로와 별개로, AWS EC2 Ubuntu 서버의 Nginx(80/443 포트)로 진입합니다.
3. Nginx는 정적 파일(Static)과 미디어 파일(Media)을 직접 서빙하거나, 동적 요청을 Gunicorn(내부 8000번 포트)으로 프록시(Reverse Proxy)합니다.
4. Gunicorn은 WSGI 서버로서 Django 애플리케이션을 구동하여 비즈니스 로직을 처리합니다.
5. Django는 관계형 데이터(회원, 게시글, 댓글 등)를 MySQL(내부 3306번 포트)에 저장 및 조회하고, 벡터 검색 및 임베딩 데이터는 ChromaDB(로컬 파일 시스템 스토어)를 통해 관리합니다.
6. AI 에이전트 및 RAG 기능 수행을 위해 외부 OpenAI API와 통신하여 답변을 생성합니다.

2. 핵심 구성 요소별 상세 설명

• **Windows PC → SSH (22):** 개발 및 관리 환경으로, SSH(22번 포트)를 통해 AWS EC2 Ubuntu 서버에 안전하게 원격 접속하여 배포, 로그 모니터링, 컨테이너 관리를 수행합니다.

• **EC2 Ubuntu:** AWS에서 제공하는 리눅스(Ubuntu) 기반의 클라우드 가상 서버(EC2)로, Docker 및 Docker Compose 환경을 구축하여 전체 프로덕션 서비스를 호스팅합니다.

• **Nginx (80/443):** 웹 서버 및 리버스 프록시(Reverse Proxy) 역할을 담당합니다. 외부의 HTTP/HTTPS 요청을 받아 정적 파일은 고속으로 서빙하고, 동적 요청은 백엔드 Gunicorn으로 안전하게 전달합니다.

• **Gunicorn (8000, 내부):** Python WSGI 애플리케이션 서버로, 멀티 프로세스 환경에서 Django 앱을 안정적으로 구동하며 외부에는 직접 노출되지 않고 내부망(Docker network) 통신만 수행합니다.

• **Django:** 파이썬 기반의 프리미엄 웹 프레임워크로, 사용자 인증, 게시판 CRUD, 파일 업로드/삭제, RAG 및 LLM 에이전트 서비스 로직 등 핵심 비즈니스 로직을 총괄합니다.

• **MySQL (3306, 내부):** 관계형 데이터베이스(RDBMS)로 회원 정보, 게시글, 답글 트리 구조, 권한 및 메타데이터를 안전하게 영구 저장합니다. 외부 포트는 차단되어 있고 내부 Docker 네트워크를 통해서만 접근 가능합니다.

• **ChromaDB (파일):** 문서 임베딩 및 벡터 검색을 수행하는 RAG 전용 벡터 데이터베이스입니다. 로컬 파일 시스템(디스크 볼륨)에 데이터를 저장하여 가볍고 빠르게 시멘틱 검색을 지원합니다.

• **OpenAI API:** 외부 AI 클라우드 서비스로, 사용자의 질문과 ChromaDB에서 검색된 관련 문서(게시글 등)를 조합하여 정교하고 자연스러운 LLM 답변을 생성하는 데 사용됩니다.

3. 프로덕션 운영 및 보안 특징

• 컨테이너 격리 및 오케스트레이션: Docker Compose를 활용하여 Nginx, Web(Django+Gunicorn), MySQL 컨테이너를 독립된 네트워크로 묶어 관리합니다.
• 데이터 영속성(Volumes): MySQL 데이터와 ChromaDB 저장소, 미디어 파일 및 정적 파일은 도커 볼륨 및 호스트 디렉토리에 마운트되어 컨테이너가 재시작되어도 데이터가 안전하게 보존됩니다.
• 보안성 강화: 데이터베이스(3306)와 Gunicorn(8000) 포트는 외부에 직접 노출되지 않으며, Nginx와 HTTPS를 통해서만 안전하게 트래픽이 제어됩니다.